



Airbnb Preisanalyse und mehr ...

Ein Data-Science-Projekt von Annette Kufner

15.1.2026, HdM Stuttgart, Modul Analytics with Statistics

Projektübersicht und Ziele

1

Lineare Regression

Airbnb Preisanalyse

2

Data-driven decision making

Was ist wann zu tun?

3

Teachercloud Entwicklung

Planung und Aufbau einer eigenen Infrastruktur für Unterrichtsmaterialien

4

KI-Tools testen


Nutzung und Evaluation vielfältiger künstlicher Intelligenz-Anwendungen

Vorgehen: Preisanalyse

- **Datenquelle:** InsideAirbnb – einheitliche Datensätze.
- **Feature-Auswahl:** Reduktion von 78 Spalten auf relevante Merkmale.
- **Datenbank:** Strukturierte Speicherung und Abfrage der Daten (PostgreSQL)
- **Zielvariable:** Preis
- **Visualisierungen**



Datenbereinigung: Fehlende Werte




Erste Modellierungsversuche

Herausforderungen bei der initialen Analyse der Daten.

1

Overplotting


Punkte überlappen sich, Muster werden undeutlich.



2

Keine Linearität


Zusammenhänge sind komplex und nicht-linear.



3

Chaos!

Lösungsansätze: ln, Feature-Engineering, ...



Zielvariable Preis: Ausreißer raus

```
# 1. Berechnung der statistischen Grenze
Q1 = df_interim['price'].quantile(0.25)
Q3 = df_interim['price'].quantile(0.75)
IQR = Q3 - Q1
upper_whisker = Q3 + 1.5 * IQR


# 2. Zählen, wie viele Zeilen übrig bleiben
total_count = len(df_interim)
kept_count = len(df_interim[df_interim['price'] <= upper_whisker])
percent_kept = (kept_count / total_count) * 100

print(f"Statistische Grenze (Upper Whisker): {upper_whisker:.2f} $")
print(f"Datensätze im Modell: {kept_count} von {total_count}")
print(f"Das entspricht: {percent_kept:.2f} % der Daten")
```


Statistische Grenze (Upper Whisker): 564.00 \$

Datensätze im Modell: 19808 von 21328

Das entspricht: 92.87 % der Daten




Zielvariable Preis: In-Transformation




- $2 \rightarrow e^2 \approx 7.40 \$$
- $4 \rightarrow e^4 \approx 54.60 \$$
- $6 \rightarrow e^6 \approx 403.40 \$$
- $8 \rightarrow e^8 \approx 2,981.00 \$$

Airbnb NYC - Preisdichte & geografische Verteilung





Einfluss der Merkmale auf den Log-Preis (ln_price)



CRISP-DM

Ein systematischer Ansatz zur Nutzung von Daten





Webapp mit Gradio

 **NYC Airbnb Preis-Experte**

Nutze dieses Tool, um den fairen Marktpreis für ein Airbnb-Inserat basierend auf unseren OLS-Analysen zu schätzen.

 **Unterkunft**

Personen (Accommodates)

1 16

2

Zimmertyp

Entire home/apt

Schlafzimmer

0 8

2

Betten

1 12

1

 **Lage & Details**

Entfernung zum Zentrum (km)

0 30

9,8

Stadtteil

Manhattan

Badezimmer

1 5

1

Anzahl Listings des Hosts

1 50


1

Preis jetzt schätzen

Analyse-Ergebnis

Geschätzter Preis: 143.98 €

Erwartete Preisspanne (aufgrund des MAE): 96.47 € bis 213.09 €



Erkenntnisse und Ausblick

Zusammenfassung der Ergebnisse und zukünftige Perspektiven.



Grenzen des Modells

Datenqualität (Querschnitt, Webscraping)

fehlende Flexibilität zur Erstellung weiterer Modellvarianten

Hardcoding

fehlende Angaben, Ausreißer, ...



Modellverbesserung

Modularer Aufbau (.py-Pipeline) hilfreich

vorhersagen für weitere Städte, gesamte USA, ...

Feature-Engineering (Aktualität, Dichte-Messungen, Textelemente aus Beschreibungen)



Data-driven decision making

Datenbank mit Inside-Airbnb-Daten ermöglicht Big Data-Modelle

Supabase als DB zur Zusammenarbeit mit anderen

Weitere ML Verfahren testen

Deployment: Docker, Kubernetes, ...

Bau einer IT-Infrastruktur

Aufräumen und Datenmanagement

The screenshot displays the TeacherCloud user interface. On the left is a sidebar with navigation links: 'TeacherCloud' (cloud icon), 'Dashboard' (house icon), 'Materials' (document icon, highlighted), 'Messages' (speech bubble icon), and 'Settings' (gear icon). The main area is titled 'My Resources' and features a search bar. Below the search bar is a table of resources with columns for Title, Type, Subject, and Date. To the right of the table is a 'Filter' panel with a 'Subject' dropdown menu and checkboxes for 'Documents', 'Presentations', 'Spreadsheets', and 'Others'. Below the filter panel is a 'Tags' section showing 'math', 'algebra', and 'curriculum' tags, along with a 'Reset' button.

Title	Type	Subject	Date
 Lesson 1	Math	Math	01/04/2023
 Algebra Basi.	Algebra	Algebra	10/03/2023
 Worksheet	Science	Science	15/02/2023
 Curriculum	Math	Math	22/01/2023

Persona



Sarah Smith



Age/Gender
32/Female



Location
New York City



Occupation
**Elementary
School Teacher**



Family Status
**Married with two
children**

Bio

Sarah is dedicated to providing high-quality education to her students and is always looking for ways to improve her teaching methods. She is tech-savvy and enjoys using digital tools to enhance her lessons.

Motivations

Sarah is motivated by seeing her students succeed and helping them reach their full potential. She also enjoys the challenge of finding innovative ways to teach and engage her students.

Devices

Laptop, smartphone, tablet

Goals

To effectively organize her teaching materials and lessons, improve student engagement and performance, and save time on lesson planning.


Pains

Sarah finds it challenging to keep track of all her teaching materials, lesson plans, and student assessments without a proper organizational system. She also struggles with finding the time to create engaging lessons while balancing her work and family responsibilities.

Brand Affiliations

Sarah is interested in technology brands that offer educational tools and resources specifically designed for teachers, such as Google Classroom, Microsoft Education, and Apple Education.

Business Model Canvas für TeacherCloud




Made with Napkin



KI-Tools im Test

Umsetzung



- Raspberry Pi
- Docker
- Nextcloud
- MongoDB
- Verschlagwortung durch Tags
- Cloud

"The medium is the message"

Marshall McLuhan, 1964

Quellen und weiterführende Literatur

- Çetinkaya-Rundel, M., & Hardin, J. (o. J.). Introduction to Modern Statistics (Kap. 7–8). [Online-Version]. <https://openintro-ims.netlify.app/>
- Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems (3. Aufl.). O'Reilly Media.
- Kirenz, J. (2021). Data Science with Python. <https://kirenz.github.io/ds-python/docs/intro.html>
- Kirenz, J. (2022). Introduction to Regression Models. <https://kirenz.github.io/regression/docs/intro.html>
- Ng, A. (o. J.). Machine Learning Specialization. [DeepLearning.AI. https://learn.deeplearning.ai/specializations/machine-learning/information](https://learn.deeplearning.ai/specializations/machine-learning/information)
- Nussbaumer Knaflic, C. (2015). Storytelling with Data: A Data Visualization Guide for Business Professionals. Wiley.

Code-Repositories & Kursunterlagen

- Kirenz, J. (2022). Regression Projekt [GitHub Repository]. <https://github.com/kirenz/regression-projekt>
- Géron, A. (2022): Example Project Workflow: Hands on Machine Learning (California housing prices) [Jupyter Notebook zum Buchkapitel oben]. https://github.com/kirenz/data-science-projects/blob/master/end-to-end/03_new_end_to_end_machine_learning_project.ipynb